

타이타닉 승객 데이터 분석 리포트

KH 정보교육원 · Python & Elasticsearch 기반 금융솔루션 개발자 아카데미 | 작성자: 이우진 | 2026-10-02

분석 파일: 20261002_데이터분석_이우진.ipynb | 데이터: Kaggle Titanic train.csv

1. 데이터 개요

타이타닉 탑승객 891명의 정보가 12개 열(생존 여부, 객실 등급, 이름, 성별, 나이, 동승 가족 수, 요금, 탑승지 등)로 구성되어 있다. 전체 생존자는 342명(38.38%), 사망자는 549명이다.

결측치가 있는 열	결측 개수	비율	처리 방법
Cabin	687	77.10%	결측이 대부분이라 분석에서 제외
Age	177	19.87%	호칭(Title)·객실 등급(Pclass) 그룹별 나이 중앙값으로 대체
Embarked	2	0.22%	개수가 적어 그대로 유지

dtype 주의점: Age는 대부분 정수 값이지만 결측치(NaN) 때문에 float64로 저장되어 있다. Survived, Pclass는 숫자형이지만 더하거나 평균 내는 수치가 아니라 생존 여부·객실 등급을 구분하는 범주형 값이며, Sex는 문자열이라 계산을 위해 0(male)/1(female)로 인코딩했다.

2. 전처리 및 파생 변수

- AgeGroup:** 나이를 아동·10대·50대·60대 이상·미확인(결측)으로 구분
- Gender_Encoded:** 성별을 male=0, female=1로 변환
- FamilySize:** SibSp(형제/배우자) + Parch(부모/자녀). 평균 0.90명, 중앙값 0명, 최대 10명 → 절반 이상이 가족 없이 혼자 탑승
- Title:** 이름에서 호칭 추출 (Mr 517, Miss 182, Mrs 125, Master 40, Dr 7)
- Age 결측치 대체:** Title과 Pclass를 동시에 고려한 그룹 중앙값으로 채워 결측 0개

3. 주요 분석 결과

① 성별·객실 등급별 생존율

Pclass	여성	남성
1등급	0.97	0.37
2등급	0.92	0.16
3등급	0.50	0.14

② 호칭별 평균 생존율


Title	승객 수	생존율
Mrs	125	0.79
Miss	182	0.70
Master	40	0.57
Mr	517	0.16

여성, 그리고 높은 객실 등급일수록 생존율이 높다. 여성 1등급은 97%가 생존했지만 남성 3등급은 14%만 생존했다. 호칭으로 보아도 기혼·미혼 여성(Mrs, Miss)과 남자아이(Master)의 생존율이 성인 남성(Mr)보다 크게 높다.

③ 나이대별 생존율

아동	10대	20대	30대	40대	50대	60대 이상	미확인
0.61	0.40	0.35	0.44	0.38	0.42	0.27	0.29

10세 미만 아동의 생존율(61%)이 가장 높고, 60대 이상(27%)이 가장 낮다.



[그림 1] 생존자·사망자 나이 분포 (히스토그램)


4세 이하 구간은 생존자가 사망자보다 많아 어린아이들이 우선 구조된 것으로 보인다. 반면 탑승객이 가장 많은 20~30대 구간은 사망자가 생존자보다 크게 많아, 전체 사망자 수에 큰 비중을 차지한다.

④ 객실 등급 × 성별 평균 요금

Pclass	여성	남성
1등급	106.13	67.23
2등급	21.97	19.74
3등급	16.12	12.66

⑤ 탑승지별 평균 요금

Embarked	평균 요금
C (세르부르)	59.95
S (사우샘프턴)	27.08
Q (퀸스타운)	13.28



[그림 2] 수치형 변수 상관관계 히트맵

- **Pclass ↔ Fare (-0.55)**: 등급 숫자가 클수록(3등급 쪽으로 갈수록) 요금이 낮다. 변수들 중 가장 강한 관계이다.
- **Survived ↔ Pclass (-0.34)**: 등급 숫자가 클수록(1등급 → 3등급) 생존율이 낮다.
- **Survived ↔ Fare (0.26)**: 요금이 높을수록 생존율이 다소 높다(약한 양의 관계).
- **SibSp ↔ Parch (0.41)**: 가족 단위로 함께 탑승한 경우가 많다.

4. 결론

생존에 가장 큰 영향을 준 요인은 **성별**과 **객실 등급**이다. 여성의 생존율이 남성보다 크게 높았고, 특히 1·2등급 여성은 90% 이상이 생존했다. 또한 나이에서는 **10세 미만 아동**의 생존율이 두드러졌다. 이는 "여성과 아이 먼저"라는 구조 원칙이 데이터에 반영된 결과로 해석할 수 있으며, 상위 등급 승객이 구조 과정에서 더 유리한 조건에 있었을 가능성도 보여준다. 요금은 객실 등급과 강하게 연결되어 있어 생존율과도 약한 양의 관계를 보였다.